
Détection de toxicité sous contraintes d'équité*

Rapport — Équité algorithmique, interprétabilité et robustesse

LATOUNDJJI Mourad NGUYEN Constance NGUYEN Le Hoang ZHANG Chengbo

13 mai 2026

1 Contexte et périmètre

Classification binaire toxique / non toxique. Nous comparons une **ToxicityGRU** (baseline) à trois variantes (répondération, adversarial, combiné), avec métriques d'équité sur 18 sous-groupes, SHAP mot à mot, et robustesse sous bruit caractère, dropout de mots et troncature. Les champs d'identité binaires suivent le schéma annoté Jigsaw ; l'EDA met en avant les groupes au biais d'étiquetage le plus marqué.

2 Protocole

Données. `id`, `target`, `comment_text` et indicateurs d'identité depuis `data/train.csv`; `toxic` dérivé de `target` au seuil 0,5. Split 80/20 stratifié (`random_state=42`), sauvegardé dans `data/split_ids.json` pour figer la répartition entre exécutions.

Modèle et encodage. Tokenizer `bert-base-uncased`, $L = 128$. **ToxicityGRU** (baseline, répondération); **FairGRU** + GRL (*Gradient Reversal*) pour adversarial et combiné.

Hyperparamètres. `SEED=42`, batch 256, 3 époques, $LR=1e-3$, `EMBED_DIM=64`, `HIDDEN_DIM=128`; adversaire : $LAMBDA_ADV=0.5$, $ADV_ALPHA=2.0$. Seuil de décision : 0,5. λ_{adv} pondère la perte adversariale dans la perte totale ($\mathcal{L} = \mathcal{L}_{tox} + \lambda_{adv} \mathcal{L}_{adv}$) : plus il est grand, plus l'encodeur est poussé à effacer le signal d'identité au prix de la performance de classification.

Métriques. AUC globale, rappel / précision; équité : BPSN, AUC épinglée, écart FPR, ECE (global et par sous-groupe); SHAP : $|\text{SHAP}|$ moyen mots d'identité vs autres; robustesse : AUC sur sous-échantillon de test perturbé.

3 EDA (synthèse)

Quatre identités concentrent le biais le plus net (`black`, `homosexual_gay_or_lesbian`, `white`, `muslim`) : taux toxiques au-dessus de la baseline annotée ($\approx 11,4\%$), forts écarts de parité, r partiel résiduel $\approx 0,11$ à $0,16$. L'annoté est **$\approx 1,4$ fois** plus toxique que le corpus brut (sur-échantillonnage). D'autres groupes (`female`, `transgender`, etc.) restent dans l'évaluation avec un signal plus faible.

4 Mitigations (méthode)

Baseline. Binaire cross-entropy classique, sans pondération ni adversaire.

Répondération. On donne plus de poids aux exemples des groupes sous-représentés ou sur-toxiques (poids inversement proportionnels au taux toxique par identité, bornés entre 0,1 et 10). L'architecture du modèle est inchangée, seule la perte est répondérée.

Adversarial + GRL. FairGRU : tête toxicité + discriminateur d'identité; GRL inverse le gradient vers l'encodeur pour appauvrir la représentation en signal d'identité.

Combiné. Pondération + objectif adversarial.

Métrique	Baseline	Répond.	Advers.	Combiné
AUC globale	0,952	0,950	0,950	0,948
AUC BPSN moy.	0,864	0,890	0,873	0,899
Écart FPR moy.	0,016	0,007	0,022	0,003
ECE globale	0,010	0,005	0,005	0,006
ECE sous-groupe moy.	0,056	0,067	0,058	0,087
Ratio SHAP identité / autre	10,3	6,3	7,8	4,9

TABLE 1 – Vue synthétique (arrondis ; meilleur par ligne en gras).

Identité	AUC BPSN				Écart FPR			
	Bas.	Répond.	Advers.	Comb.	Bas.	Répond.	Advers.	Comb.
black	0,799	0,862	0,842	0,894	0,041	0,007	0,037	0,002
homosexual...	0,801	0,853	0,832	0,877	0,044	0,016	0,053	0,009
transgender	0,839	0,872	0,863	0,893	0,016	0,006	0,027	−0,002
muslim	0,825	0,872	0,849	0,890	0,031	0,007	0,032	0,005
white	0,807	0,872	0,848	0,901	0,037	0,005	0,031	0,002
christian	0,928	0,928	0,908	0,914	0,000	0,001	0,005	−0,001

TABLE 2 – Détail par identité : AUC BPSN (colonnes 2–5) et écart FPR (colonnes 6–9 ; proche de 0 favorable). Gras = meilleur dans chaque bloc de quatre valeurs.

5 Résultats

Constats. Agrégats (table 1). Toute mitigation coûte 0,002–0,004 d’AUC globale. La **répondération** améliore l’équité agrégée à coût minime et reste la plus **résiliente au bruit caractère**. L’**adversarial** seul, à $\lambda_{\text{adv}} = 0,5$ sur trois époques, est **sous-contraint** : il aggrave l’écart FPR moyen ($>$ baseline) et ne réduit que peu le ratio |SHAP| identité/autre. Le **combiné** atteint la meilleure équité sous-groupes (BPSN, FPR) et la plus forte chute de la signature identitaire (p. ex. token **black** : 0,248 $\rightarrow$ 0,078).

Identités (table 2). Le combiné est meilleur sur 5/6 groupes en BPSN comme en écart FPR ; les gains se concentrent sur les identités les plus biaisées en EDA (**black**, **white**). L’adversarial seul aggrave le FPR sur **homosexual_gay_or_lesbian** et **transgender**. Le contrôle **christian** reste stable.

Robustesse (Annexe A). Dégradation comparable des quatre variantes ; la répondération domine en bruit caractère modéré, le combiné reste dans la fourchette basse — coût attendu de la double contrainte.

Arbitrage. Le vrai trade-off n’est pas entre BPSN et FPR (le combiné les améliore conjointement) mais entre équité sous-groupes et AUC globale + calibration par sous-groupe : le combiné dégrade l’ECE sous-groupe (0,087 vs 0,056 baseline). On retient donc le combiné pour minimiser FPR/BPSN par identité, la répondération pour un équilibre performance / équité / robustesse.

6 Limites

Peu d’époques et λ_{adv} modéré ; GRU sur tokens BERT sans fine-tuning du transformeur ; métriques sensibles à la taille des sous-groupes ; robustesse seulement sur perturbations synthétiques ; SHAP sur petit échantillon, interprétation non causale.

7 Conclusion

Sur le sous-ensemble Jigsaw annoté, les quatre identités les plus biaisées en EDA bénéficient principalement du **combiné**, qui minimise l’écart FPR et la BPSN par sous-groupe tout en atténuant la signature identitaire mesurée par SHAP. La **répondération** reste le compromis le plus équilibré entre performance, équité globale et robustesse au bruit, alors que l’**adversarial** seul, sous-contraint à $\lambda_{\text{adv}} = 0,5$ sur trois époques, dégrade le FPR moyen. Le choix de mitigation doit donc être guidé par la priorité applicative : équité par identité, calibration par sous-groupe ou robustesse aux entrées dégradées.

*Claude Opus a été utilisé pour aider à générer une partie du code et améliorer la rédaction de ce rapport. Le choix des méthodes, la conception des expériences, l’analyse des limites et l’interprétation des résultats ont été réalisés par les auteurs.

Annexe A D tail robustesse

Perturbation	Niveau	Baseline	R�pond.	Advers.	Combin�
Bruit caract�re	0,00	0,951	0,949	0,952	0,947
	0,05	0,872	0,895	0,875	0,876
	0,10	0,824	0,821	0,800	0,817
	0,20	0,688	0,698	0,655	0,695
Dropout mots	0,0	0,951	0,949	0,952	0,947
	0,1	0,929	0,928	0,930	0,922
	0,2	0,904	0,922	0,916	0,908
	0,3	0,900	0,881	0,896	0,884
Troncature (L)	128	0,951	0,949	0,952	0,947
	64	0,936	0,932	0,937	0,930
	32	0,905	0,897	0,907	0,895
	16	0,821	0,821	0,828	0,826

TABLE 3 – Robustesse : AUC sur sous- chantillon de test perturb . Bruit caract re (probabilit  de substitution par caract re), dropout al atoire de mots, troncature de la s quence (L jetons). Gras = meilleur par ligne.